

请参阅本出版物的讨论、统计资料和作者简介：<https://www.researchgate.net/publication/352418881>

## 用于黄金期货价格预测和算法交易的新型混合VMD-ICSS-BiGRU方法

文章发表在IEEE《计算社会系统》杂志上 - 2021年6月

doi: 10.1109/iccsc.2021.3084847

引用

1

阅读文章

183

4作者，包括。



李玉泽

多伦多大学

22出版物引文106

[查看简介](#)



王寿阳

中国科学院

810出版物引文16,445

[查看简介](#)



朱庆

陕西师范大学

34出版物引文309

[查看简介](#)

本出版物的一些作者也在从事这些相关项目的工作。



气候损害评估 [查看项目](#)



国家自然科学基金项目，资助号：71473155 [查看项目](#)

本页以下内容均由[Qing Zhu](#)于1115月上传 2021.

用户要求对下载的文件进行改进。

# 用于黄金期货价格预测的新的VMD-ICSS-BiGRU混合方法和算法交易

李玉泽<sup>1</sup>，王守阳<sup>2</sup>，魏云杰<sup>3</sup>，朱庆<sup>4</sup>

## 摘要

黄金市场在世界经济中发挥着重要作用。由于其复杂和非稳态的性质，预先决定黄金价格是特别具有挑战性的。在这项研究中，通过整合BiGRU深度学习模型、VMD和迭代累积平方和算法，提出了一种新的混合预测方法，即变模分解（VMD）-迭代累积平方和（ICSS）-

双向门控递归单元（BiGRU）。该预测框架能够提取黄金期货市场走势中的内在因素和规律，分解其与外部市场的相关性，并检测市场条件的转变，从而准确预测黄金期货市场的价格走势。实验结果表明，与基准相比，混合预测方法可以显著提高预测性能。此外，我们将提出的混合预测方法扩展到生成交易策略并测试黄金期货市场的交易性能。在几年的样本外期间（2008-

2019年）的测试结果表明，基于所提方法的预测生成的策略在产生正收益方面显示出高度的一致性，并在各种市场条件下优于其他几种常见的交易策略。该方法在推广到现货黄金市场时也显示出一致的较好结果，为黄金商品市场的投资风险最小化和对冲策略提供了实际指导。

## 指数

算法交易、双向门控递归单元（BiGRU）、黄金期货价格预测、变模分解（VMD）。

稿件于2020年8月12日收到；2021年3月29日修订；5月接受本16,2021.工作得到国家自然科学基金委的资助和71801213拨款（71988101.通讯作者：魏云杰。）

李玉泽，中国科学院数学与系统科学研究院，北京，100190；中国科学院大学经济与管理学院，北京，中国100190，（电子邮件：richardyz.li@mails.ucas.ac.cn）。

王守阳，中国科学院数学与系统科学研究院，北京，100190；中国科学院大学经济与管理学院，北京，100190；中国科学院预测科学中心，北京，中国100190，（电子邮件：sywang@amss.ac.cn）。

魏云杰是中国科学院数学与系统科学研究院，北京，100190，同时也是中国科学院预测科学中心，北京，中国100190，（电子邮件：weiyunjie@amss.ac.cn）。

朱庆在中国710000,西安陕西师范大学国际商学院工作（电子邮件：zhuqing@snnu.edu.cn）。

数字对象标识符10.1109/TCSS.2021.3084847

2329-924x © 2021 IEEE. 允许个人使用，但再版/转发需经IEEE许可。  
更多信息见<https://www.ieee.org/publications/rights/index.html>。

## I. 简介

GOLD是金融市场上最重要的商品之一，它在世界经济中发挥着重要作用[1]。对于许多国家来说，黄金是中央银行储备的主要部分，因为它被用作价格控制杠杆和战略经济资源[2]。对于许多投资者来说，黄金是一种有价值的资产，作为投资的安全天堂，可以用来对冲价格上涨和其他金融风险[3]。在贵金属市场上，黄金是最常见的投资商品[4]。因此，准确预测黄金的价格对投资者、投资组合经理以及政策制定者来说是非常重要的。例如，它可以创造巨大的投资机会，使投资者受益，因为预测精度的小幅提高可以产生巨大的利润[5]。然而，黄金市场不仅具有非平稳性和波动性，而且还受到各种因素的影响，如投资者的预期、相关的市场运动和政治事件[6]。因此，由于其复杂性，预测黄金市场的趋势仍然是时间序列中最具挑战性的领域之一。

预测[7]。

这篇文章与两股文献有关。首先是关于黄金市场的影响因素的研究。众多研究分析了诸如外汇汇率和原油价格等输入变量对贵金属市场的影响[8]。例如，[9]、[10]和[11]发现，美元（USD）等汇率在预测商品价格方面具有明显的预测能力。此外，[12]、[13]和[14]得出结论，石油价格是一个主要的宏观经济因素，对黄金的价格波动具有显著的解释力，显示出两个市场之间接近85%的高度相关性。尽管之前的研究已经考察了这些外部变量的影响，并将其纳入到黄金价格波动的预测中，但这些研究中纳入的因素主要由外部市场的原始可观察价格变量组成。然而，由于不同因素对黄金价格的影响时间不同[15]，这些可观察的变量可能不足以完全反映外部市场对黄金市场的影响。在本文中，我们选择了四个外部市场作为输入变量，包括布伦特原油（LCO），西德克萨斯中质原油（WTI），美元指数（DXY）和黄金现货美元（XAUUSD）。为了进一步提取黄金现货之间的隐藏关系

本文利用变量模式分解（VMD）将选定的外部市场的价格信息分解为不同频率的子序列。市场之间的整体相关性是通过市场子序列之间的多种相关性来模拟的。这种新颖的

"相关性分解"代表了黄金期货市场和其他外部市场之间的关系，这使得该模型能够发现黄金期货市场的内在因素和选定的外部市场之间的隐藏关系。

第二类文献涉及金融市场预测中所采用的预测模式。在早期研究中，传统的计量经济学方法被用于预测商品价格。一些常用的模型包括移动平均模型（MA）、自回归模型（AR）、自回归移动平均模型（ARMA）[16], [17], 以及广义自回归条件异方差模型（GARCH）[18], [19]。

前面提到的数学模型有一个主要的缺点，就是这些模型都有线性和静止性的假设，这很难满足金融市场的复杂和非静止的性质。因此，这些假设往往会产生糟糕的预测结果[20]。为了克服这些限制并利用计算技术的快速发展，研究人员在金融市场预测中采用了深度学习方法。深度学习是一种特殊类型的人工神经网络（ANNs），由多个隐藏层组成。与传统的计量经济学方法相比，它包含了增强的功能表示能力，并显示出卓越的性能[21], [22]。例如，[23]利用深度信念网络（DBN）与受限玻尔兹曼机（RBM）相结合，在股票指数预测中取得了不错的效果。Zhao等人[24]提出了一个引导聚合和叠加去噪自动编码器（SDAE）来预测石油价格。Doering等人[25]使用卷积神经网络（CNN）在基于高频数据预测股票价格。Deng等人[26]将深度直接强化（DDR）方法、模糊深度直接强化（FDDR）方法与递归深度神经网络（RDNN）结合起来预测中国期货市场。Fischer和Krauss[27]利用长短期记忆（LSTM）网络来预测标普股票在2012年和1992-2013年500之间的市场趋势。2015.此外，[28]应用深度CNN来识别股票和交易所交易基金的买入、卖出和持有点。

为了进一步提高预测能力，人们提出了一种基于分而治之概念的集合学习方法。这种方法首先将原始金融时间序列分解为不同的周期因子，然后整合这些因子的预测结果[29], [30]。Yu等人[31]采用互补集合经验模式分解（CEEMD）和扩展极端学习机（EELM）的混合方法来预测原油价格。[15]利用CEEMD将国际黄金的历史价格分解为价格成分，并结合支持向量机（SVM）和ANN来预测黄金价格。Wang等人[32]提出了一种新型的两阶段的

通过整合CEEMD和VMD的分解技术，以及反向传播神经网络（BPNN）来预测北京和上海的电价和空气质量指数。然而，这种方法的缺点之一是，分解产生的预测误差可能会累积，这对模型的预测能力产生负面影响[33]。

为了利用上述方法并克服其各自的局限性，本文通过整合信号分解技术、结构断点检测和循环神经网络，提出了一种混合的深度神经网络方法来预测黄金期货价格。首先，采用变模分解（VMD）作为信号分解技术，将原始复杂的非稳态时间序列分解为简单的稳态子序列。这些子序列作为输入特征的一部分被输入到预测模型中，这使得模型能够捕捉到数据的内在模式。第二，几个技术指标，如简单移动平均线（SMA）被作为模型输入。第三，利用迭代累积平方和（ICSS）算法来识别市场的结构性断点。检测到的结构性断点通过一个二元虚拟变量被纳入预测模型，该变量描述了市场条件的变化。此外，选定的外部市场的分解子序列，以及与黄金期货市场子序列的各自相关性，被用作代表外部市场因素的输入特征。最后，所有上述特征被输入到模型中以预测黄金期货市场的价格。正如[34]所提出的，时间序列数据是双向的，这意味着当前状态是过去状态的反映，是未来状态的基础。与以往的深度学习模型假设时间序列数据只包含单向关系不同，本文提出的方法采用了双向门控递归单元（BiGRU）的方法，从前进方向和后退方向提取信息。所提出的方法是完全由数据驱动的，需要较少的假设，这使得它与现实更加一致。据我们所知，这是第一个在黄金市场预测应用中结合信号分解、结构断裂检测和双向深度学习结构的方法。为了验证该模型的实用性，预测结果被用来识别黄金期货价格的买入、卖出和持有点，并生成交易策略。评估结果表明，所提出的方法始终优于其他一些选定的普通交易策略。此外，该方法被应用于现货黄金市场，显示出一贯的卓越交易表现。

本文的其余部分组织如下。第二节概述了该模型的理论概念设计。第三节介绍了实证结果和财务表现。第四节总结并提供未来工作的计划。

## II. 理论概念设计

本节介绍了拟议的VMD-ICSS-BiGRU混合深度学习方法的理论概念设计

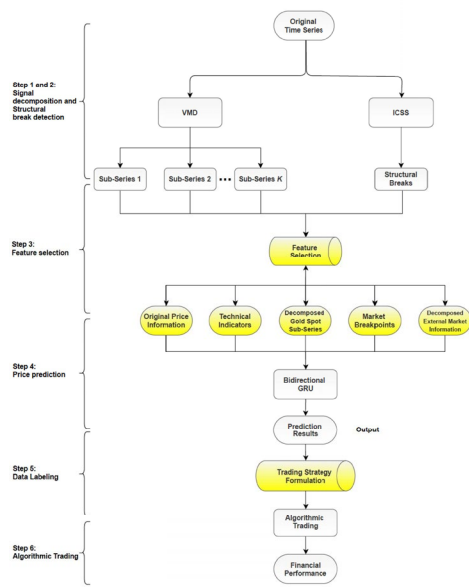


图1：拟议的VMD-ICSS-BiGRU混合方法的框架1。

在黄金期货市场上预测黄金期货价格和进行算法交易。第II-A节概述了所提出的方法，第II-B-II-G节分别描述了该方法的主要步骤，以及相关技术。

#### A. 拟议设计概述

为了提高黄金期货市场的预测准确性，一个混合的深度神经网络模型，该模型结合信号分解技术、结构断裂点检测，并提出了递归神经网络。所提出的方法是完全由数据驱动的，需要的假设较少，这使得它与现实更加一致。此外，为了进一步验证预测模型的实用性，根据预测结果制定了交易策略，并将交易结果与其他常用策略进行了比较。提出的方法如图所示。1.

##### 步骤（1信号分解）。

一个有效的信号分解技术，即VMD，被用来将原始时间序列 $x_t(t1,2,...,T)$ 分解成 $K$ 个简单和静止的子序列，使模型能够捕获数据的内在模式。

##### 步骤（2结构断裂检测）。

一个结构性断点检测算法，迭加累积平方和（ICSS），被用来识别时间序列中的 $N$ 个结构性断点，这些断点代表了市场条件的重大变化。相应的 $N$ 个市场条件用一个二元虚拟变量来描述。

##### 步骤（3特征选择）。

几个特征组件，包括原始的黄金期货价格信息，其技术指标，检测的结构断点、分解的子序列和几个外部市场信息被选为预测模型的特征输入。

##### 步骤（4价格预测）。

采用BiGRU作为预测工具，生成黄金期货价格的预测结果。此外。

在1天、2天和3天的范围内进行多步预测，以测试该方法的稳健性。

##### 步骤（5数据标签化）。

为了进一步评估该方法的预测准确性和财务表现。根据资产的每日收盘价和对数回报率，样本中的每个数据点都被标记为“持有”、“买入”或“卖出”点。

##### 步骤（6算法交易）。

根据上一步制定的数据标签规则，产生的提前一天的预测结果被用来制定交易策略。将制定的策略与其他几种常见的交易策略进行比较，以评估其财务表现。

#### B. 信号分解

在信号分解中，利用的是VMD。VMD是在[35]中提出的一种新开发的自适应和非递归的信号分解方法。总的来说，它将维纳滤波概括为若干自适应波段，将多组合的输入信号 $f(t)$ 分解为一组准正交的离散带限子序列模式 $u_k$ ，同时再现输入信号 $f(t)$ 。

分解得到的模式主要是紧紧围绕中心频率 $w_k$ 的中心[37]。从本质上讲，VMD是一个变异优化问题，它寻求最小化每个模式的带宽，这可以用以下方式表示 following form:

$$\min_{\{u_k\}, \{w_k\}} \sum_k \int_{-\infty}^{\infty} \left| \frac{\partial_t}{\partial_t} \delta(t) + \frac{1}{\pi t} \otimes u_k(t) \right|^2 e^{-j w_k t} dt \quad (1)$$

s.t.  $u_k = f(t)$

其中 $u_k$ 表示 $k$ 个子系列模式， $w_k$ 表示它们各自的中心频率， $f(t)$ 是输入信号， $\delta(t)$ 表示狄拉克三角函数，表示卷积算子。每个模式的优化过程是通过以下步骤进行的。[38]

- 1) 通过希尔伯特变换将每个子信号模式转换成单边频谱。
- 2) 使用一个指数函数调整到相应的估计中心频率，每个子系列模式的频谱被改变为窄频基带。
- 3) 每个子信号模式的带宽是通过求解调信号进行H型高斯平滑度计算的。

为了计算（1）中约束优化问题的最优解，可以引入二次惩罚函数和拉格朗日乘数来解决约束。因此，可以得到增强的拉格朗日修正方程，如（2）所示

$$\begin{aligned} & \{u_k\}, \{w_k\}, \lambda \\ & = \alpha \int_{-\infty}^{\infty} \left| \frac{\partial_t}{\partial_t} \delta(t) + \frac{1}{\pi t} \otimes u_k(t) \right|^2 e^{-j w_k t} dt \\ & + \int_{-\infty}^{\infty} \left| f(t) - \sum_k u_k(t) \right|^2 dt + \int_{-\infty}^{\infty} \lambda(t) \left( f(t) - \sum_k u_k(t) \right) dt \quad (2) \end{aligned}$$



其中 $\alpha$ 表示二次惩罚函数， $\lambda$ 表示拉格朗日乘数。

(2)的解是用替代方向得到的

乘法 (ADMMs) [39]。估计的子信号模式从时域转移到频域。

子信号模式 $u_k$ 和中心频率 $w_k$

在 (3) 和 (4) 中计算如下。

$$\hat{u}_k^{n+1}(w) = \frac{\hat{f}(w) - \sum_{i=1}^n \hat{u}_i(w) + \frac{\lambda(w)}{2}}{1 + 2\alpha(w - w_k)^2} \quad (3)$$

$$w_k^{n+1} = \frac{\int_0^\infty |u(w)|^2 dw}{\int_0^\infty |u(w)|^2 dw} \quad (4)$$

### C. 结构断裂检测

为了识别时间序列中代表市场条件重大变化的结构性中断，采用了ICSS算法。ICSS算法是在[40]中提出的，是一种用于检测时间序列中结构性中断的常用方法。该算法假设一个时间序列有一个静止的方差，直到发生断点。然后，它将有另一个静止的方差，直到下一个断点。通过迭代过程，时间序列中的所有断点都可以被识别。

让 $C = \sum_{t=1}^T k_t^2$ ， $k_1, k_2, \dots, k_T$ 是累积的平方残差之和，其中 $k$ 表示平均数为0，方差为 $\sigma^2$ 的残差序列<sup>2</sup>。那么统计量 $D_k$ 可以在 (5) 中定义如下。

$$D_k = \frac{C_k}{CT}, k=1, 2, \dots, T, D = D_k = 0. \quad (5)$$

如果在样本期没有结构性中断，则方差没有变化， $D_k$ 将保持在左右。0。

然而，如果发生结构断裂， $D_k$ 将偏离0。具体来说，如果偏移量超过临界值，就会确定一个断点。在本文中，临界值被设定为以下数值

在[40]中定义的5%的显著性水平上。

### D. 特征选择

用作模型输入的特征包括两套组件。第一组包含四类来自黄金期货市场的特征--

原始价格信息、技术指标、分解的收盘价子系列和市场断点。原始价格信息由每日对数回报和5日回报波动率组成，直接反映了市场价格的变化。对数收益率是指某一商品的对数收益率。它的计算方法如下 (6)。

$$\ln \frac{p_t}{p_{t-1}} \quad (6)$$

其中 $p_t$ 表示时间 $t$ 的收盘价， $p_{t-1}$ 表示时间 $t-1$ 的收盘价<sup>1</sup>。

此外，收益率的波动性衡量的是收益率的分散性。

在一定时期内商品的平均回报率的百分比。通常情况下，波动性越大的商品，其收益就越高。

投资风险。在本文中，标准差被用作衡量波动性的指标。它的计算方法如下 (7)。

$$v_t = \sqrt{\frac{1}{n} \sum_{i=1}^n (r_i - \bar{r})^2} \quad (7)$$

其中 $r_t$ 表示时间 $t$ 的对数收益， $\bar{r}$ 是计算期内的平均对数收益， $n$ 是计算中使用的天数， $v_t$ 表示 $n$ 天的波动率。

该资产在金融分析中，基本面分析和技术分析都被广泛用于开发金融产品。时间序列模型[41]。一方面，基本分析-

该模型根据经济状况、公司收益、负债等影响因素评估市场动向。

资产，和管理。另一方面，技术分析利用金融价格的过去表现来推断未来的动向。通过使用技术指标，它消除了经济因素中的主观性。在这项研究中，选择了几个技术指标来描述黄金期货市场的运动趋势，其中包括均线、指数移动平均线 (EMA)、相对强度指数 (RSI) 和威廉姆斯% R。

均线是一定期限内资产价格的算术MA。有许多涉及SMA的交易策略被广泛使用。通常情况下，不同时间间隔的多个SMA可以一起使用，以确定市场的趋势方向。例如，如果资产价格高于SMA线，就会触发一个"买入"信号，表明市场正显示出上升的趋势。与此相反。

如果资产价格低于SMA线，就会触发"卖出"。表明市场呈现下降趋势的信号。

SMA的计算方法如下 (8) 所示

$$SMA = \frac{1}{n} \sum_{t=a+1}^{a+n} p_t \quad (8)$$

其中 $p_t$ 表示时间 $t$ 的资产价格， $n$ 表示计算中的时期数。

与SMA不同，EMA是一种加权的MA，对最近的价格数据分配更多的权重。与SMA相比，EMA对最近的价格变化反应更灵敏。它的计算方法如 (9) 所示

$$EMA_t = (p_t - EMA_{t-1}) * \frac{2}{n+1} + EMA_{t-1} \quad (9)$$

其中 $EMA_{t-1}$ 表示前一时期的EMA， $(2/n+1)$ 是应用于最新价格数据的加权乘数。

RSI是一个震荡指标，显示资产的势头。RSI在0和100之间震荡，表示资产的"超买"和"超卖"状况。通常情况下，如果RSI值高于70，该资产被认为是"超买"，如果RSI值低于30，则被认为是"超卖"。

RSI的方程式如下 (10)

$$RSI = 100 - \frac{100}{1 + \frac{\text{平均收益}}{\text{平均损失}}} \quad (10)$$

威廉姆斯%R是另一个资产价格的动量震荡指标。该指标的值在100和0之间震荡。与RSI类似，如果该值高于20,资产被认为是“超买”。如果该值低于该80,资产被认为是“超卖”。计算方法为威廉姆斯%R显示如下

$$\text{威廉姆斯\%R} = \frac{\text{最大(高)} - p_t}{\text{最大(高)} - \text{最小(低)}}. \quad (11)$$

VMD被用作信号分解技术，将原始的复杂和非平稳的时间序列分解为 $K$ 个简单和平稳的子序列。这使得模型能够捕捉到数据的内在规律。正如[15]所言，由于不同因素对黄金价格的影响时间不同，原始黄金价格时间序列可以分解为不同频率的成分，以反映市场上不同的价格运动模式。这些子序列可以有效地捕捉到不同因素对黄金期货市场运动的影响。因此，将原始黄金价格时间序列分解为不同的子序列可以产生有意义的信息，使模型能够了解市场在不同时间区间的运动模式。

此外，由[40]提出的ICSS算法被用来识别黄金期货价格对数回报的结构断点。这些断点代表了市场回报率波动的变化，它被用作代表市场条件转变的信号。因此，一个二元虚拟变量，市场条件，被纳入代表市场的状态。在每个样本之后，断点被不断地重新识别。如果没有发生断点，二元变量的值保持不变。如果检测到一个断点，二元变量的值就会改变，表明市场条件的变化。迭代过程不断重复，直到所有样本都被使用。总的来说，检测到 $N$ 个结构性断点，这就转化为 $N$ 个市场1条件值。

第一组特征来自于黄金期货市场。然而，只纳入其自身的市场信息可能不足以完全反映其价格走势。如[42]所示，黄金期货价格被发现与其他主要金融市场的价格相关联。因此，相关市场的变动可能对黄金期货价格的波动有重大影响。因此，来自几个外部金融市场的信息被纳入，以反映隐藏的关系。以前的研究已经调查了黄金和其他外部变量之间的关系。Batten 等人[12]得出结论，石油价格是影响黄金价格波动的一个主要宏观经济因素。此外，[13]还发现，石油价格对黄金价格波动行为具有显著的解释力，显示出两个市场之间的高度关联性。除了石油价格外，还有一些研究如

[11]显示黄金价格和美元之间存在负的因果关系。此外，现货黄金经常被作为一种资产来对冲黄金期货的价格波动。如[43]所示，现货黄金和黄金期货的价格波动之间存在着显著的关系。基于上述证据，我们选择了四个主要的金融市场指数来


代表外部市场的影响。世界上两个主要的原油指数，LCO和WTI原油（WTI），被用来代表石油市场。美国DXY，是衡量美元相对于其他外国货币包括欧元、日元、英镑、加拿大元、瑞典克朗和瑞士法郎的价值，被用来作为美元外汇市场的综合指标。最后，XAUUSD被用来反映现货黄金市场的波动情况。

在以前的研究中纳入的变量主要包括来自外部市场的可观察的市场信息。然而，这种表述可能不足以充分反映它们与黄金期货市场的隐性关联。与黄金期货类似，外部市场的价格波动也有不同的时间模式。因此，在本研究中，外部市场的价格被分解成不同的子序列，分别提取内在的模式。由于黄金价格的波动受到不同频率因素的影响，黄金期货市场的不同子序列与外部市场的相关性可能会有很大差异。例如，频率较高的黄金期货子序列和频率较高的WTI原油子序列与频率较高的黄金期货子序列和频率较低的WTI原油子序列可能具有不同的相关性。因此，与以前的研究相比，我们提出了一种新的相关性表示，即市场之间的整体相关性被进一步分解为市场子序列之间的多种相关性。这种相关性分解使模型能够进一步提取黄金期货市场和选定的外部市场之间的隐藏关系。此外，由于市场的复杂性质，不同市场子序列之间的相关性不会随着时间的推移而保持不变。因此，5天的滑动皮尔逊相关系数被选为动态关系的衡量标准。在这项研究中，滑动皮尔逊相关系数是在黄金期货市场的每个分解子序列和外部市场的子序列之间计算的。每个分解的外部市场子序列都乘以其相应的相关系数，以生成输入的外部市场部分的特点。

## E. 价格预测

与传统的神经网络只能在迭代的方向上使用单方向的时间序列历史信息不同，在价格预测的步骤中引入了双向的神经网络。正如[34]所总结的，时间序列数据包含了双向的顺序关系，因为当前状态不仅是历史信息的反映，也是未来状态的基础。因此，双向的神经网络更符合现实。本文采用BiGRU方法，从前进方向和后退方向提取信息。

双向递归神经网络（BiRNN）是由[44]提出的。与传统的RNN只利用单方向的历史信息不同，BiRNN利用了双向的历史信息，这样它就可以获得过去和未来状态的信息。此外，在这篇文章中，传统的RNN单元被门控电流所取代



图：双向GRU结构的详细2.架构。

在[45]中提出的单元（GRU）。与普通的RNN单元不同，GRU单元能够准确地模拟长距离的依赖关系[46]。如图所示，一个2,GRU单元由一个复位门 $r_t$ 和一个更新门 $z_t$ 组成。复位门， $r_t$ ，控制着从上一个状态丢弃的信息量。 $r_t$ 的值越大，从前一状态中丢弃的信息就越多。更新日期， $z_t$ ，决定了单元中输入信息的更新量。 $z_t$ 的值越大，单元中更新的输入信息就越多。它们的计算结果如（12）-

（16）所示

$$r_t = \sigma(W_r - [h_{t-1}, x_t]) \quad (12)$$

$$z_t = \sigma(W_z - [h_{t-1}, x_t]) \quad (13)$$

$$\tilde{h}_t = \tanh(W_{\tilde{h}} - [r_t * h_{t-1}, x_t]) \quad (14)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t \quad (15)$$

$$y_t = \sigma(W_o - h_t) \quad (16)$$

其中 $x_t$ 表示时间 $t$ 的输入信息， $h_t$ 表示 $h_t$ 是候选激活向量。

$\sigma$ 是Leaky-ReLu激活函数。 $W_r, W_z$ 和 $W_{\tilde{h}}$ 是

加权矩阵，\*是元素相乘。

双向GRU（BiGRU）模型有两个隐藏层，其中一个层用于处理前进方向的信息，另一个层用于处理后退方向的信息。最后，这两个隐藏层连接到一个输出层。通过利用两层结构，BiGRU可以通过提取过去和未来状态的信息来做出更准确的预测。

#### F. 数据标签

为了进一步评估拟议方法的预测准确性和财务表现，根据资产的每日收盘价，将所有数据点标记为"持有"、"购买"或"出售"点。在本研究中，标签策略以成对的形式标记"买入"和"卖出"点。如果时间 $t$ 的每日收盘价高于时间 $t$ 的收盘价，时间 $t$ 被标记为"买入"，时间 $t+1$ 被标记为"卖出"。然后标签算法继续进行到时间 $t+2$ 。否则，时间 $t$ 被标记为"持有"，算法继续进行到时间 $t+1$ 。

#### G. 算法交易

从模型中产生的预测结果被用来根据上一步中概述的数据标签规则制定交易策略。

在自动贴标后，根据生成的策略进行交易。在我们的方法中，黄金期货根据预测的标签被购买、出售或持有。如果预测的标签是"买入"，则在该时间戳用所有可用资金买入黄金期货。如果预测的标签是"卖出"，并且该资产之前已经被买入，则在该时间点全部卖出。如果预测的标签是"持有"，则不进行任何交易。在这个模拟中，初始资本被设定为1000美元 000。

为了比较所提出的方法的性能，我们选择了其他单一和混合人工智能（AI）模型制定的交易策略，以及三种传统策略--

买入和持有（B&H），均线 and RSI作为基准。在买入和持有策略中，黄金期货在每个测试区间开始时被买入，在每个测试区间结束时被卖出，中间没有进行任何交易。在均线策略中，每个交易日都会计算出20天的均线值。如果对应日的收盘价高于其20日均线值，则该数据点被标记为"卖出"点。相反，如果该日的收盘价低于其20日均线值，则该数据点被标记为"买入"点。否则，它将被标记为"持有"点。同样，在RSI策略中，每个交易日的14天RSI值被计算出来。根据惯例，如果交易日的相应RSI值日大于该70,资产被认为是"超买"，它被标记为"卖出"点。如果RSI值小于30,该资产被认为是"超卖"，它被标记为"买入"点。否则，它将被标记为"持有"点。对于每个测试区间，每个策略的年化收益为计算结果如（17）所示

$$AR = \frac{\text{最终资本} - \text{初始资本}}{\text{年数}} \times 100 \quad (17)$$

#### 实证研究

为了测试拟议模型的有效性，从黄金期货市场和外部市场中选出的特征被用作拟议的VMD-ICSS-GRU方法的输入。评估程序由两部分组成。首先，该模型的预测性能与其他预测模型（包括单一和混合人工智能模型）进行比较。第二，利用模型预测产生的交易策略在黄金期货市场上进行金融交易。其财务表现与几个传统和人工智能交易策略进行了比较。

#### A. 数据描述

本文旨在根据过去的市场运动模式、技术指标、分解的子系列、市场状态的结构性变化以及与其他金融市场的相关性，对黄金期货市场--黄金期货（GC）指数进行准确预测并建立有效的交易策略。原始数据从雅虎财经（www.finance.yahoo.com）获得。原始数据集包含了从1月1到110,2000,月黄金期货的每日价格数据，其中25,2019,






图3.商品交易所（COMEX）黄金期货日收盘价的正常化1个月前的趋势




图4.根据资产的每日对数回报计算的1个月远期COMEX黄金期货的5日波动率。

包括4981个数据点。每个数据点包含每日开盘价，收盘价，最高价和最低价。在算法交易中，收盘价被用作预测目标和制定交易策略的基础。图中3分别4,显示了其趋势和5天的波动性概况。为了测试预测的有效性，我们采用了滚动测试区间的方法，将总数据的55%作为测试数据。

点。正如[47]中所建议的，测试数据被分为分为几个子5区间。第一个区间是从七月到9,2008,一月5,2010.第二个区间是从一月开始6,2010,10,2011.第三个区间是从10月到11,2011,11月5,2013.第四个区间是从10月到11月。2013年11月6,,到201612,年4月。最后一个区间是从四月至13,2016,一月25,2019。

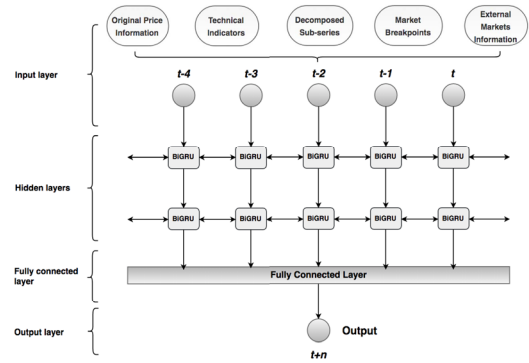
为了消除不同尺寸的影响和为了获得更好的模型性能，在(18)1所示的范围内对0数据进行归一化。

$$x = \frac{x - \min x}{\max x - \min x} \quad (18)$$

其中 $x$ 表示数据的归一化值， $x$ 表示是数据的真实值， $\max x$ 和 $\min x$ 分别是数据的最大值和最小值。

## B. 预测模型结构

图5描述了拟议的混合模型的结构。实验过程包括两个步骤。1) 将每日收盘价作为目标变量来衡量模型的预测性能。使用VMD将其分解为不同的简单和静止的子序列。五个主要的特征成分，包括原始价格，其技术指标，分解的子序列的内部因素，检测到的市场断点，以及外部市场。



图：详细5.的模型网络结构。

信息被用作模型的输入变量。该模型以5天的窗口长度 $t$ 到 $4t$ 为输入，将信息通过两个堆叠的双向GRU层和一个全连接层。然后，它预测黄金期货在时间戳 $t+n$ 的每日收盘价。

2) 预测输出被用来标记测试集中的数据点并生成交易策略。然后根据生成的策略进行交易，并将该模型的交易性能与几个传统策略进行比较。

## C. 评价标准

为了评估模型的预测性能，平均平方误差（MSE）因其稳健性而被选为损失函数。MSE越小，预测器的估计质量就越好。它的计算方法如（19）所示

$$MSE = \frac{1}{N} \sum_{t=1}^N (\hat{X}(t) - X(t))^2 \quad (19)$$

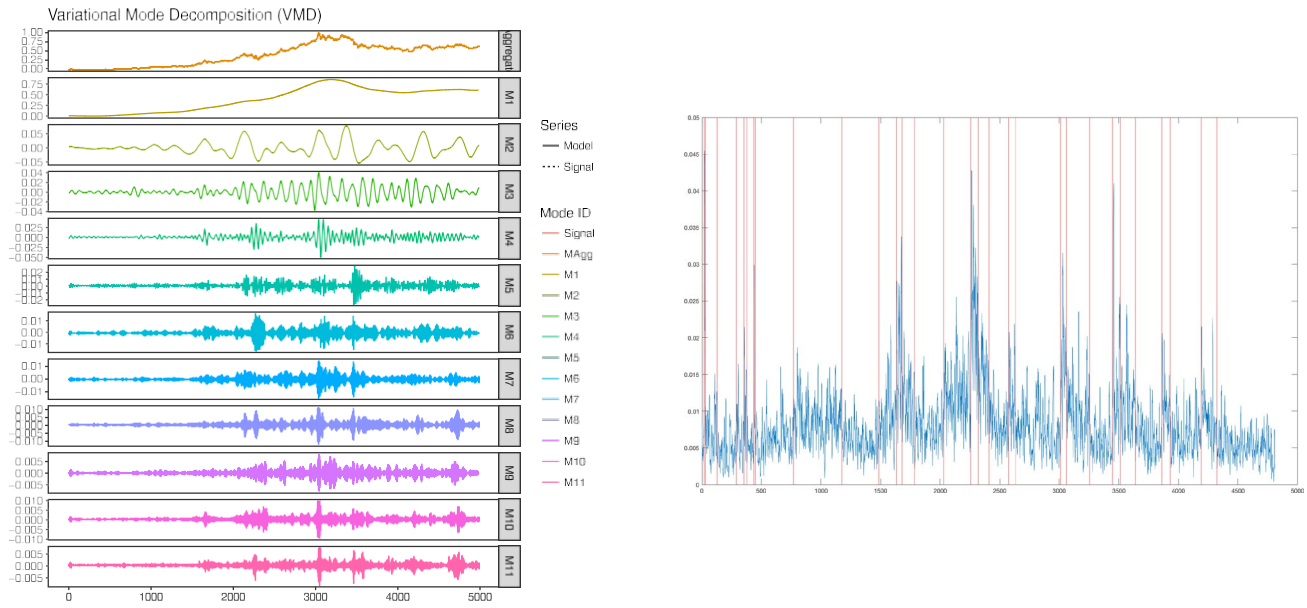
衡量拟议模型的拟合性能。平均平方根误差（RMSE）、平均百分比误差（MAPE）和平均绝对误差（MAE）被选中。它们的计算方法是：(20)-(22)

$$MAPE = \frac{1}{N} \sum_{t=1}^N \frac{X_t - \hat{X}_t}{X_t} \quad (20)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{t=1}^N (\hat{X}_t - X_t)^2} \quad (21)$$

$$MAE = \frac{1}{N} \sum_{t=1}^N |\hat{X}_t - X_t| \quad (22)$$

一个好的预测模型不仅需要良好的拟合性能，还必须具有较高的预测能力，才能在真实的金融世界中实用。因此，引入了方向性准确性（DA）来评估模型的可预测性。一方面，如果模型预测资产收盘价第二天会上涨（下跌），而实际价格上涨（下跌），那么模型的预测是成功的。另一方面，如果模型预测资产收盘价将在第二天上升（下降），而实际价格下降（上升），那么模型预测就成功了。



图：左边的子图6.图是黄金期货每日收盘价的分解子系列。右边的子图为一个数据点检测到的结构断裂点。

失败了。DA越大，模型的预测能力就越高。DA的计算方法如 (23) 和 (24) 所示

$$Z_t = \begin{cases} 1, & \text{如果 } (X_t - X_{t-1}) - (\hat{X}_t - \hat{X}_{t-1}) \geq 0 \\ 0, & \text{如果 } (X_t - X_{t-1}) - (\hat{X}_t - \hat{X}_{t-1}) < 0 \end{cases} \quad (23)$$

$$\frac{DA_i=1}{N} = \frac{\sum_{t=1}^N Z_t}{N} \quad (24)$$

其中 $\bar{X}_t$ 是实际值的平均值， $N$ 是总数量的数据点， $\hat{X}_t$ 和 $X_t$ 分别表示时间 $t$ 的预测值和实际值。

## D. 实证结果

1) **预测性能。**为了避免在预测过程中使用未来信息，获得更真实的性能，我们只使用VMD来分解训练数据集。需要注意的是，由于我们采用的是滚动测试的方法，我们每次在纳入上一个测试区间的数据后都会进行VMD分解。为了说明问题，我们在图6的左边子图中显示了整个数据的全部分解结果。正如[47]所建议的，我们将资产的收盘价分解为不同频率的子11信号模式。如图所示，这些6.模式从低频率到高频率，M1是最低频率，M11是最高频率。每个子系列代表了时间序列中的一个隐藏的振荡因素。最低频率的模式，M1，能够捕捉到数据的长期相对长期趋势。较高频率的模式，M2-M11，描绘了数据中的相对短期价格波动，这意味着它们可以有效地捕捉市场中敏感的短期噪音。

图6的右侧子图说明了模型对其中一个数据点检测到的结构断裂点。

的样本。由红线标记的断点代表了市场回报率波动的变化，表明市场条件的转变。因此，一个虚拟变量，市场

条件，被用来代表市场的状态。的。在每个训练日之后，断点被不断地重新确定。如果一个断点没有发生，那么市场的价值就会下降。

条件变量保持不变。如果出现断点，就会分配一个不同的市场条件值，表示一个市场状态的转变。

在对原始复杂的非平稳信号进行分解并确定市场条件的转变后，将选定的输入变量送入堆叠的BiGRU模型，以预测黄金期货一天、两天和三天的收盘价。由于黄金期货的收盘价与它在近期的价格有密切的关系，所以使用了一个5天的连续训练窗口。例如，在提前一天预测的情况下，前几天的5训练数据

$$x_{t-4}, x_{t-3}, x_{t-2}, x_{t-1}, x_t$$

，其中 $x_t$ 包括原始投入，技术指标，分解后的子系列内部因素。

1.为了评估模型的预测性能，我们进行了纵向和横向的性能比较，将已确定的市场条件和第 $t$ 天的外部市场信息输入BiGRU模型，以预测目标变量 $y_{t+1}$ ，也就是第 $t$ 天的收盘价。

与几个基准模型。为了进行纵向比较，我们选择了单一的BiGRU模型和VMD-

BiGRU混合模型。具体来说，BiGRU模型不包括作为其输入的解构的内在模式。VMD-

BiGRU模型包括所有的组成部分，如技术指标、原始黄金价格和外部市场信息，除了已确定的市场断点作为其输入。为了进行横向比较，我们使用最先进的技术，如支持向量回归 (SVR)、线性回归 (LR)、ANN以及LSTM，构建了几个基准模型。

表一  
不同模型的纵向预测性能

	Model	RMSE	MAPE	MAE	DA
1-Step	BiGRU	0.0124	0.0158	0.0113	0.5012
	VMD-BiGRU	0.0071	0.0074	0.0043	0.7958
	Proposed	<b>0.0057</b>	<b>0.0062</b>	<b>0.0035</b>	<b>0.8351</b>
2-Step	BiGRU	0.0163	0.0214	0.0157	0.5035
	VMD-BiGRU	0.0092	0.0098	0.0051	0.7533
	Proposed	<b>0.0063</b>	<b>0.0069</b>	<b>0.0041</b>	<b>0.7929</b>
3-Step	BiGRU	0.0172	0.0206	0.0171	0.5116
	VMD-BiGRU	0.0105	0.0107	0.0062	0.7314
	Proposed	<b>0.0067</b>	<b>0.0074</b>	<b>0.0045</b>	<b>0.7587</b>

表二  
按区间划分的纵向预测性能

	Model	RMSE	MAPE	MAE	DA
Interval 1	BiGRU	0.0121	0.0153	0.0115	0.5027
	VMD-BiGRU	0.0075	0.0072	0.0038	0.7986
	Proposed	<b>0.0063</b>	<b>0.0067</b>	<b>0.0031</b>	<b>0.8358</b>
Interval 2	BiGRU	0.0129	0.0162	0.0115	0.5066
	VMD-BiGRU	0.0069	0.0068	0.0044	0.7903
	Proposed	<b>0.0057</b>	<b>0.0062</b>	<b>0.0037</b>	<b>0.8363</b>
Interval 3	BiGRU	0.0126	0.0154	0.0118	0.4973
	VMD-BiGRU	0.0068	0.0077	0.0041	0.7864
	Proposed	<b>0.0061</b>	<b>0.0053</b>	<b>0.0038</b>	<b>0.8296</b>
Interval 4	BiGRU	0.0127	0.0149	0.0117	0.5058
	VMD-BiGRU	0.0074	0.0075	0.0052	0.7881
	Proposed	<b>0.0059</b>	<b>0.0058</b>	<b>0.0030</b>	<b>0.8315</b>
Interval 5	BiGRU	0.0126	0.0162	0.0129	0.5007
	VMD-BiGRU	0.0073	0.0072	0.0034	0.8014
	Proposed	<b>0.0053</b>	<b>0.0066</b>	<b>0.0035</b>	<b>0.8278</b>

为了确保模型之间的一致性，我们利用分解的时间序列和确定的市场断点作为所有这些模型的输入。纵向性能比较结果见表一和表二。横向性能结果显示在表三中。值得注意的是，所有的归一化预测结果都是在没有非归一化过程的情况下进行评估的。

在1步超前预测方面，单一BiGRU模型的RMSE、MAPE和MAE分别为0.0124、0.0158和0.0113。然而，该模型整体和所有区间的DA值（见表一）都低于60%，这意味着该模型没有能力预测市场趋势。相比之下，当引入VMD分解后，混合VMD-BiGRU能够减少预测误差，提高拟合性能。此外，模型的DA值增加到0.7958，这表明

该模型能够预测营销趋势。因此，这表明在BiGRU模型中引入信号分解可以显著提高模型的预测能力。通过VMD分解，提取的内在因素以及不同市场的子序列之间的分解相关性包含了与黄金期货市场波动密切相关的信息。此外，当引入ICSS来识别市场条件的变化时，提出的方法产生了超前期结果。与纯分解的VMD-BiGRU模型相比，所提出的方法能够进一步减少所有区间的预测误差，这表明其拟合性能更强。此外，DA值进一步提高到0.8351，这表明所提出的方法不仅在数学计算中可以接受，而且在现实世界的应用中也很实用。

表三  
不同模型的水平预测性能

	Model	RMSE	MAPE	MAE	DA
1-Step	SVR	0.0133	0.0128	0.0094	0.6573
	LR	0.0139	0.0129	0.0108	0.6159
	ANN	0.0088	0.0094	0.0062	0.7314
	LSTM	0.0063	0.0069	0.0041	0.8258
	Proposed	<b>0.0057</b>	<b>0.0062</b>	<b>0.0035</b>	<b>0.8351</b>

表四  
不同策略的年化收益

Interval	VMD-ICSS-BiGRU	VMD-BiGRU	Buy & Hold	SMA	RSI
Interval 1	<b>31.59%</b>	25.00%	10.98%	7.41%	9.76%
Interval 2	<b>23.22%</b>	6.75%	20.96%	7.70%	-0.11%
Interval 3	<b>7.91%</b>	-1.48%	-11.19%	-12.20%	0.05%
Interval 4	<b>14.35%</b>	4.67%	-1.88%	-7.59%	8.19%
Interval 5	<b>14.43%</b>	13.10%	1.45%	-23.26%	1.91%
Overall	<b>20.41%</b>	12.48%	2.95%	-7.82%	3.73%

通过对2步超前和3步超前预测结果的检验，所提出的方法能够一致地减少预测误差，有效地提高拟合性能。因此，结合信号分解技术和结构断点检测来识别市场条件的变化可以有效地捕捉到黄金期货市场的运动趋势。此外，研究表明，双向神经网络结构能够学习时间序列数据中存在的双向序列关系。

作为进一步验证的证据，如表三所示，当我们提出的方法与用最先进的技术构建的基准模型进行比较时，它也能够有效地减少预测误差并提高预测的DA。因此，所有这些结果表明，我们提出的方法能够有效地捕捉市场模式并提高预测性能。

2) 财务业绩。为了评估拟议策略的财务业绩，混合VMD-BiGRU模型、买入和持有、20日均线线和14日RSI被用作基准，以比较不同区间的年化收益。由于单一的BiGRU模型无法预测市场趋势，因此不用于进行金融交易。所有策略在不同区间的财务表现如表四所示，其中每个区间年化收益最高的策略用黑体字标注。总的来说，拟议的VMD-ICSS-BiGRU方法在整个测试集中的年化收益率为20.41%。相比之下，VMD-BiGRU模型、Buy & Hold和RSI分别获得12.48%、2.95%和3.73%的回报。同时，SMA经历了7.82%的损失。考察结果，很明显

拟议的VMD-ICSS-BiGRU方法在每个区间都获得了最高的回报，显示出比其他策略的优势。值得注意的一点是，当所有其他策略在一个或多个区间内遭受损失时，由拟议方法产生的策略能够在所有测试区间内获得稳定的年化正收益。正如[28]所言，在很长一段时间内持续战胜市场是特别具有挑战性的。在本研究中，测试集跨越了从到2008的年份11在2019.这段时间里，市场表现出不同的波动模式。与其他交易策略不同的是，当黄金期货市场状况悲观或高度波动时，所提出的模型能够避免损失，并持续从市场中获得正利润。在其他交易策略表现不佳、回报率为负数的几个时期，所提出的方法显示出卓越的表现，产生了显著的正利润。因此，在市场条件悲观或高度波动的情况下，它特别有效和稳定。此外，无论市场条件如何，拟议的方法能够在所有测试期持续产生正收益。总的来说，所提出的模型显示出高度的稳定性，特别是显示出强大的能力来减少次优市场条件的负面影响。因此，该模型能够有效降低黄金期货的投资风险，从而为投资者和金融机构提供实际意义。

3) 现货黄金的财务表现。为了进一步验证提议的VMD-ICSS-BiGRU方法的稳健性，我们将其应用于现货黄金市场的数据。与黄金期货数据类似，现货黄金样本由1月至10,200,1月的4981个数据点组成，25,2019.Likewise。






图7：对现货黄金市场进行金融交易的不同策略的可用资本的变化。测试期为1月10日至20001月 所有可用资本的25,2019.货币为美元。

黄金期货的特征包括原始输入，其技术指标，分解的子序列内部因素，市场断点，和外部市场信息。在这种情况下，子序列内部因素是从现货黄金的每日收盘价中提取的。使用的外部市场信息是WTI原油，LCO，和黄金期货。最初的资本被设定为

\$1000

000.在这个模拟中，85%的数据被用作训练集，其余的被用作测试集。因此，测试集包括从2016年4月13日到2019年1月25日的747个实例。模型结构与黄金期货模拟保持不变。拟议的VMD-ICSS-

BiGRU方法的财务业绩与其他四种策略--VMD-

BiGRU、买入并持有、SMA和RSI进行了比较。在测试区间内，提议的方法获得了17.07%的年化收益，而VMD-BiGRU、买入并持有、SMA和RSI获得的收益分别为12.30%、1.52%、4.64%和5.84%。相比之下，拟议方法的平均年化策略不仅在测试期间获得了正的利润，而且产生的利润也明显高于其他策略获得的利润。图进一步说明了我们的策略与其他策略之间的性能比较。

#### IV. 结论

在这项研究中，通过整合BiGRU深度学习模型、VMD和迭代累积平方和算法，提出了一种名为VMD-ICSS-BiGRU的混合深度学习方法来预测黄金期货市场的价格变动。首先，变模分解（VMD）被用作信号分解技术，将原始的复杂和非平稳的时间序列分解成简单和平稳的子序列。这些子序列作为输入特征的一部分被输入到预测模型中，这使得模型能够捕捉到数据的内在模式。第二，几个技术指标被作为模型输入。第三，利用ICSSs算法来识别市场的结构断点。我们的实证结果表明，与其他单一和混合深度学习模型相比，拟议的VMD-ICSS-BiGRU方法显示出卓越的预测性能结果。它能够持续产生正

无论市场条件如何，它的回报率都很高。特别是，它表现出很强的能力来减少恶化和不明确的市场条件的负面影响。此外，该模型在不同的数据集上的一致表现表明它是可推广的。因此，它为投资者和政策制定者提供了实际意义和指导。

我们研究的局限性之一是，所提出的策略是一个只做多的策略。然而，在现实中，空头也是市场策略的一个重要组成部分。目前，由于模型等待买入和卖出信号，所提出的策略持有时间相对较长，因此，包括空头可能会产生更多的机会，并大大增加利润。因此，采用混合多头和空头策略的方法将是未来工作的方向。

#### 参考文献

- [1] G. Aye, R. Gupta, S. Hammoudeh, and W. J. Kim, "Forecasting the price of gold using dynamic model averaging," *Int. Rev. Financial Analogue.Rev. Financial Anal.*, 第41,257-266页, 10月. 2015.
- [2] C.Ciner, C. Gurdiev, and B. M. Lucey, "Hedges and safe havens:对股票、债券、黄金、石油和汇率的考察," *Int. Rev. Financial Analogue*, "国际金融分析", "对冲和安全避风港:股票、债券、黄金、石油和汇率的考察". *Rev. Financial Anal.*, 第202-211页29,, 9月. 2013.
- [3] M.F. Ghazali, H. H. Lean, and Z. Bahari, "Is gold a hedge or a safe haven?马来西亚的黄金和股票的经验证据," *Int.J. Bus.* 第428-443页3,, Jan.J.Bus.Soc., Vol.No14,, 2013.
- [4] K.Gangopadhyay, A. Jangir, and R. Sensarma, "预测黄金的价格。误差修正法," *IIMB Manage.Rev.*, 第28卷, 第1期, 第6-12页, 3月. 2016.
- [5] D.Liu and Z. Li, "Gold price forecasting and related influence factors analysis based on random forest," in *Proc. 10th Int. Conf.Conf.Management.Sci. Eng. 管理.*, J. Xu, A. Hajiyeve, S. Nickel, and M. Gen, Eds.新加坡. Springer, 第711-723页2017,.
- [6] R.Gupta, S. Hammoudeh, W. J. Kim, and B. D. Simo-Kengne, "使用动态模型平均法预测中国的外汇储备。The roles of macroeconomic fundamentals, financial stress and economic uncertainty," *North Amer.J. Econ.Finance*, vol. pp28,, 170-189, Apr. 2014.
- [7] C.Zhang, Z. Pu, and Q. Zhou, "东北亚的可持续能源消费。A case from China's fuel oil futures market," *Sustain- ability*, vol. no10,, pp1,,1-14, Jan. 2018.
- [8] L.-T.Zhao, Y. Wang, S.-Q.Guo, and G.-R.Zeng, "A novel method based on numerical fitting for oil price trend forecasting," *Appl. Energy*, vol. pp220,,154-163, Jun. 2018.
- [9] Y.-C.Chen, K. S. Rogoff, and B. Rossi, "Can exchange rates forecast commodity prices?SSRN *Electron.J.*, vol. 125, no.3, pp. 1145-1194, Aug. 2010.
- [10] J.C. Reboredo, "黄金是安全港还是美元的对冲? Implications for risk management," *J. Banking Finance*, vol. 37, no. 8, pp.2665-2676, Aug. 2013.
- [11] B.Mo, H. Nie, and Y. Jiang, "Dynamic linkages between gold market, US dollar and crude oil market," *Phys. A, Stat. Mech.Mech.Appl.*, 第491卷, 第984-994页, 2月. 2018.
- [12] J.A. Batten, C. Ciner, and B. M. Lucey, "The macroeconomic determinants of volatility in 贵金属市场", *Resour.* pp.2,65-71, Jun. 2010.
- [13] S.Shafiee和E. Topal, "全球黄金市场和黄金价格预测概述", *Resour.政策*, 第35,1 78-189页3,, 9月. 2010.
- [14] N.B. Behmiri 和 M. Manera, "异常值和石油价格冲击对金属价格波动的作用", *Resour.政策*, 第46卷, 第139-150页, 12月. 2015.
- [15] F.Wen, X. Yang, X. Gong, and K. K. Lai, "Multi-scale volatility feature analysis and prediction of gold price," *Int. J.Information.J. Inf.Technol.Decis. 制作*, 第16,205-223页1,, 1月. 2017.
- [16] A.Parisi, F. Parisi, and D. Díaz, "预测黄金价格变化。滚动和递归神经网络模型," *J. Multinat.金融管理.*, 第18,477-487页5,, 12月. 2008.

这篇文章已被接受列入本刊的未来一期。内容为最终呈现，页码除外。

- [17] T.Kriechbaumer, A. Angus, D. Parsons, and M. R. Casado, "An improved wavelet-ARIMA approach for forecasting metal prices, " *Resour. 政策*》，第32-41页39,, 3月。 2014.

- [18] L.Fang, B. Chen, H. Yu和Y.Qian, "全球经济政策的不确定性在预测黄金期货市场波动中的重要性。 A GARCH-MIDAS approach," *J. Futures Markets*, vol. no38,, pp3,,413-422, Mar. 2018.
- [19] E.Tully 和 B. M. Lucey, "A power GARCH examination of the gold market," *Res. Int. Bus.Bus.金融*, 第21,316-325页2,, 6月。 2007.
- [20] L.Yu, S. Wang, and K. K. Lai, "Forecasting crude oil price with an EMD-based neural network ensemble learning paradigm, " *Energy Econ.*第30,2623-2635页5,, 9月。 2008.
- [21] Y.Bengio, "Learning deep architectures for AI," *Found.Trends Mach.Learn.*, 卷号2,, 第1-127页1,. 2009.
- [22] Y.LeCun, Y. Bengio, and G. Hinton, "Deep learning," *自然*, 第521卷, 第436-444页, May 2015.
- [23] T.Kuremoto, S. Kimura, K. Kobayashi, and M. Obayashi, "Time series forecasting using a deep belief network with restricted Boltzmann machines," *Neurocomputing*, vol. no137,, pp15,,47-56, August. 2014.
- [24] Y.Zhao, J. Li, and L. Yu, "A deep learning ensemble approach for crude oil price forecasting," *Energy Econ.*, 第9-16页66,, 8月。 2017.
- [25] J.Doering, M. Fairbank, and S. Markose, "Convolutional neural networks applied to high-frequency market microstructure forecasting," in *Proc. 9th Comput.Sci. Electron.Eng.(CEEC)*, 9月, 第31-36页2017.。
- [26] Y.Deng, F. Bao, Y. Kong, Z. Ren, and Q. Dai, "Deep direct reinforcement learning for financial signal representation and trading, " *IEEE Trans.Neural Netw.Learn.Learn. Syst.*, 第28,653-664页3,, 3月。 2017.
- [27] T.Fischer and C. Krauss, "Deep learning with long short-term memory networks for financial market predictions," *Eur. J. Operat.J. Oper.Res.*, 第270卷, 第654-669页2,, 10月。 2018.
- [28] O.B. Sezer和A. M. Ozbayoglu, "使用深度卷积神经网络的算法金融交易。时间序列到图像的转换方法," *Appl. Soft Comput.*, 第525-538页70,, 9月。 2018.
- [29] Q.Wang, W. Xu, X. Huang, and K. Yang, "Enhancing intraday stock price manipulation detection by leveraging recurrent neural networks with ensemble learning," *Neurocomputing*, vol. 347, pp.46-58, Jun. 2019.
- [30] J.Xiao, Y. Tian, L. Xie, X. Jiang, and J. Huang, "A hybrid classification framework based on clustering," *IEEE Trans.Ind.Informat.*第16卷, 第2177-2188页4,, 4月。 2020.
- [31] L.Yu, Z. Wang, and L. Tang, "A decomposition-ensemble model with data-characteristic-driven reconstruction for crude oil price forecast," *Appl. Energy*, vol. pp156,, 251-267, Oct. 2015.
- [32] D.Wang, S. Wei, H. Luo, C. Yue, and O. Grunder, "A novel hybrid model for air quality index forecasting based on two-phase decomposition technique and modified extreme learning machine, " *Sci. Total Environ.*, 第719-733页580,, 2月。 2017.
- [33] L.Tang, S. Wang, K. He, and S. Wang, "A novel mode-charistic- based decomposition ensemble model for nuclear energy consumption forecasting," *Ann.Oper.*第234,111-132页1,, 11月。 2015.
- [34] R.Kadari, Y. Zhang, W. Zhang, and T. Liu, "CCG supertagging via bidirectional LSTM-CRF neural architecture," *Neurocomputing*, vol. 283, pp.31-37, Mar. 2018.
- [35] K.Dragomiretskiy和D.Zosso, "变量模式分解". *IEEE Trans. 信号处理*., 第62,531-544页3,, 2月。 2014.
- [36] Y.Wang and R. Markert, "Filter bank property of variational mode decomposition and its applications," *Signal Process.*, 第120卷, 第509-521页, 3月。 2016.
- [37] W.Liu, S. Cao, and Y. Chen, "Variational mode decomposition in seismic time-frequency analysis, " *Geophysics*, vol. 81, no.V365-V378, Sep. 2016.
- [38] C.Zhang, J. Zhou, C. Li, W. Fu, and T. Peng, "A compound structure of ELM based on feature selection and parameter optimization using hybrid backtracking search algorithm for wind speed forecast, " *Energy Convers.管理*., pp.143, 360-376, Jul. 2017.
- [39] M.R. Hestenes, "Multiplier and gradient methods," *J. Optim.理论应用*, 第303-320页4,, 11月。 1969.
- [40] C.Inclán和G. C. Tiao, "Use of cumulative sums of squares for retrospective detection of changes of variance, " *J. Amer.Stat.*第89,913-923页427,, 9月。 1994.
- [41] R.C. Cavalcante, R. C. Brasileiro, V. L. F. Souza, J. P. Nobrega, and A.L. I.Oliveira, "计算智能和金融市场。 A survey and future directions," *Expert Syst. Appl.Appl.*, 第55卷, 第194-211页, 8月。 2016.
- [42] K.K. Kanjilal 和 S. Ghosh, "Dynamics of crude oil and gold price post 2008 global financial crisis-New evidence from threshold vector error-correction model, " *Resour.政策*, 第358-365页52,, 六月。 2017.
- [43] W.Kristjanpoller 和 M. C. Minutolo, "Gold price volatility:使用人工神经网络-GARCH模型的预测方法, " *Syst.*7245-7251, Nov42,20,, 2015.

- [44] M.Schuster和K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Trans.信号过程*。第45卷, 第11期, 第2673-2681页, 11月。1997.
- [45] K.Cho, B. van Merriënboer, D. Bahdanau, and Y. Bengio, "On the properties of neural machine translation:编码器-解码器方法,"在*Proc.8 Workshop Syntax, Semantics Struct.Stat.* 翻译。(SSST-8), 第103-111页2014。
- [46] J.Chung, C. Gulcehre, K. Cho, and Y. Bengio, "Empirical evaluation of gated recurrent neural networks on sequence modeling, " in *Proc.NIPS Workshop Deep Learn.*, 12月, 第1-9页2014。
- [47] Q.Zhu, F. Zhang, S. Liu, Y. Wu, and L. Wang, "A hybrid VMD-BiGRU model for rubber futures time series forecasting, " *Appl. Soft Comput.*, 第11卷84,, Art2019,.No. 105739.

**李玉泽**目前正在中国科学院数学与系统科学研究院攻读管理科学与工程专业的硕士学位。

他的研究兴趣包括经济建模、分析、预测和博弈论。他曾在《*自然通讯*》、《*欧洲运筹学杂志*》和《*能源经济学*》等杂志上发表文章。



**王守阳**于2009年在中国北京中国科学院系统科学研究所获得操作研究的博士学位。1986.

他目前是中国科学院数学与系统科学研究院管理科学领域的白求恩特聘教授。他曾获得许多与研究有关的奖项和荣誉。他在国际学术期刊上发表了多篇单图35和文章330。他是/曾经是大学的学生。

期刊的特刊/卷的客座编辑。他的研究兴趣包括决策分析和预测。



**魏云杰**于2017年获得中国科学院数学与系统科学研究院的管理科学与工程博士学位, 并于2017年获得香港城市大学的管理科学博士学位。2018.

她目前是中国科学院数学与系统科学研究院的助理教授。她已在国际学术期刊上发表了20多篇文章。她的研究兴趣包括经济建模, 以及分析和预测。



**朱清**是陕西师范大学国际商学院的金融学教授, 同时也是西安交通大学管理学院的数据科学博士后研究员。他的研究兴趣是大数据和软计算, 机器学习, 和神经网络。